Predicción del Riesgo de Enfermedad Cardiovascular usando Machine Learning

Camilo A. Cuellar
Facultad de Ingeniería
Universidad de Antioquia
Medellín, Colombia
camilo.cuellar@udea.edu.co

Lukas Piedrahita
Facultad de Ingeniería
Universidad de Antioquia
Medellín, Colombia
lukas.piedrahita@udea.edu.co

Felipe Uribe
Facultad de Ingeniería
Universidad de Antioquia
Medellín, Colombia
f.uribe@udea.edu.co

***Resumen*—Las enfermedades cardiovasculares representan un desafío crítico de salud pública a nivel global. El uso de algoritmos de Machine Learning permite explotar la riqueza de los registros clínicos electrónicos para optimizar los procesos de detección temprana. En este trabajo se presenta el diseño metodológico de un sistema de clasificación binaria supervisada entrenado sobre un conjunto de datos masivo de 70,000 registros médicos. Se detalla un protocolo riguroso de filtrado fisiológico para mitigar errores de digitalización, seguido del planteamiento de un diseño experimental que compara de forma sistemática cinco familias independientes de modelos predictivos. Finalmente, se propone evaluar el impacto de técnicas de reducción de dimensionalidad lineales y no lineales, buscando un equilibrio óptimo entre la interpretabilidad clínica y la eficiencia computacional del sistema.**

***Palabras Clave*—Enfermedad cardiovascular, Machine Learning, Clasificación binaria, Filtrado clínico, Reducción de dimensionalidad.**

I. Introducción

Las enfermedades cardiovasculares constituyen una de las principales causas de morbilidad y mortalidad a nivel mundial, representando aproximadamente el 32% de todas las muertes globales [1]. Esta alarmante prevalencia hace necesario el desarrollo de herramientas tecnológicas avanzadas que permitan la detección temprana y una adecuada estratificación del riesgo antes de la aparición de eventos clínicos severos.

El uso de técnicas de Machine Learning (ML) resulta altamente pertinente en este escenario debido a su capacidad para modelar relaciones complejas y no lineales entre múltiples variables clínicas, demográficas y comportamentales, facilitando la identificación de patrones sutiles asociados a la presencia de la enfermedad. En particular, este problema se formula como una tarea de clasificación binaria supervisada, donde el objetivo fundamental es predecir la presencia o ausencia de patología cardiovascular a partir de características accesibles en la evaluación inicial, tales como la edad, la presión arterial, los niveles de lípidos y los hábitos de vida del paciente.

Si bien la predicción del riesgo cardiovascular mediante técnicas de aprendizaje automático ha sido ampliamente estudiada en la literatura, persisten desafíos relacionados con la calidad de los datos clínicos, la comparación consistente entre modelos y la comprensión del impacto de las técnicas de reducción de dimensionalidad sobre el desempeño predictivo. En este contexto, el presente estudio propone una metodología estructurada en tres etapas. Primero, se implementa un protocolo de curaduría de datos basado en rangos de plausibilidad clínica reportados en la literatura especializada, con el fin de mitigar inconsistencias y errores de registro. Segundo, se realiza una evaluación comparativa sistemática de cinco enfoques algorítmicos representativos, incluyendo modelos paramétricos, no paramétricos, ensambles basados en árboles, redes neuronales y máquinas de vectores de soporte, bajo condiciones experimentales homogéneas. Finalmente, se examina el efecto de técnicas de reducción de dimensionalidad lineal (PCA) y no lineal (UMAP) sobre la capacidad predictiva de los modelos, buscando identificar configuraciones que equilibren precisión, eficiencia computacional e interpretabilidad para su potencial aplicación en entornos clínicos.

II. Descripción del Problema

Se estima que aproximadamente 523 millones de personas en todo el mundo viven con alguna forma de enfermedad cardiovascular, lo que refleja su profundo impacto social y económico [2]. Como problema crítico de salud pública, requiere sistemas auxiliares de diagnóstico clínico que optimicen la toma de decisiones médicas basadas en datos históricos. El presente proyecto aborda este desafío a partir de un conjunto de datos masivo compuesto originalmente por 70,000 muestras epidemiológicas y clínicas estructuradas.

La base de datos se caracteriza por no poseer valores faltantes en su matriz de origen y agrupa un total de 11 variables predictoras junto a una variable objetivo binaria denominada *cardio*, la cual codifica la presencia (1) o ausencia (0) de la patología cardiovascular. Las variables de entrada recopiladas se clasifican conceptualmente en tres categorías:

- **Información Objetiva y Antropométrica:** Incluye la edad del paciente (registrada originalmente en días), la estatura (medida en centímetros), el peso corporal (medido en kilogramos) y el género (codificado de forma binaria como 1 para mujeres y 2 para hombres).
- **Resultados de Exámenes Clínicos:** Incorpora métricas críticas de presión arterial, discriminadas en presión sistólica (*ap_hi*) y presión diastólica (*ap_lo*), ambas en milímetros de mercurio (mmHg). Asimismo, incluye dos

variables ordinales que categorizan los niveles de colesterol y glucosa en tres escalas cualitativas (1: normal, 2: elevado y 3: muy elevado).

- **Factores Subjetivos y Hábitos de Vida:** Contempla tres indicadores binarios auto-reportados por los pacientes (donde 0 representa la ausencia y 1 la presencia del factor) relativos al hábito de fumar (*smoke*), el consumo regular de alcohol (*alco*) y el mantenimiento de una actividad física constante (*active*).

Durante el análisis del contexto clínico se identificó la presencia de valores inconsistentes y atípicos extremos en variables de alta sensibilidad como la estatura, el peso y, de forma más crítica, en los registros de presión arterial. Fenómenos como presiones arteriales negativas o valores sistólicos superiores a los 10,000 mmHg denotan fallos humanos en los procesos de digitalización manual. Para salvaguardar la fidelidad biológica del entrenamiento de los modelos, se diseñó una estrategia de depuración basada en los límites internacionales de extracción segura de datos electrónicos [6]. Dicho protocolo establece como intervalos de plausibilidad médica rangos de 50 a 260 mmHg para la presión sistólica, de 0 a 200 mmHg para la presión diastólica, de 100 a 250 cm para la estatura y de 40 a 200 kg para el peso corporal total. Todas aquellas muestras que violen estas restricciones fisiológicas son descartadas del proceso experimental, garantizando que los modelos aprendan exclusivamente de distribuciones humanas realistas.

III. Estado del Arte

El diseño de modelos de aprendizaje automático enfocado en la estimación del riesgo cardiovascular ha evolucionado aceleradamente, transitando desde la analítica estadística tradicional hacia arquitecturas híbridas avanzadas y plataformas automatizadas de screening.

En un estudio reciente desarrollado por Mo et al. [3], se propuso un paradigma supervisado de dos capas denominado TLML que acopla los algoritmos de *Random Forest* y *Gradient Boosting Decision Tree*. El modelo fue validado rigurosamente sobre una cohorte hospitalaria retrospectiva de gran escala que abarcó 20,821 pacientes con diagnóstico confirmado y 9,796 controles sanos estudiados entre los años 2017 y 2024. Los autores demostraron que este enfoque de ensamble superó notablemente los sistemas tradicionales de puntuación clínica como las Ecuaciones de Cohortes Agrupadas (PCEs), logrando un balance óptimo en la detección in situ mediante la evaluación concienzuda de la exactitud, la sensibilidad y la especificidad del clasificador.

Por su parte, Bibi et al. [4] recurrieron al uso de Machine Learning Automatizado (AutoML) con el propósito de predecir niveles de lipoproteína(a) y estimar tasas de mortalidad cardiovascular general. Su estrategia metodológica se estructuró en tres fases de desarrollo utilizando los conjuntos de datos de los estudios clínicos LURIC ($n = 3,316$) y UMC/M ($n = 423$). En este trabajo se implementaron clasificadores basados en árboles y redes neuronales residuales, validando los resultados a través del Análisis SHAP (*Shapley Additive exPlanations*) para identificar variables predictoras clave como el uso de estatinas y la concentración de biomarcadores cardíacos. El estudio priorizó la robustez predictiva midiendo de forma central el área bajo la curva ROC.

En el ámbito de los clasificadores basados en fronteras de decisión, Kakadiaris et al. [5] desarrollaron un estimador de riesgo utilizando Máquinas de Vectores de Soporte (SVM) para el tratamiento del desbalance de clases. Los modelos fueron entrenados utilizando el estudio MESA (*Multi-Ethnic Study of Atherosclerosis*), el cual cuenta con un seguimiento prospectivo a 13 años de 6,459 participantes sanos en su línea base. La robustez científica del estimador SVM fue contrastada mediante una validación externa independiente utilizando la cohorte epidemiológica del estudio FLEMENGHO. Los hallazgos revelaron una reducción significativa en la sobreprescripción innecesaria de terapias farmacológicas (como estatinas) y una tasa de omisión de eventos de riesgo marcadamente inferior a los calculadores clínicos estandarizados norteamericanos.

Finalmente, Adusumilli et al. [6] plantearon un análisis comparativo global evaluando los algoritmos de Regresión Logística, *Random Forest* y SVM sobre registros de salud electrónicos exhaustivos. Su investigación demostró que los enfoques fundamentados en ML mejoran significativamente la eficiencia computacional y la precisión predictiva cuando son sometidos a procesos selectivos de ingeniería de características. Los autores enfatizaron que la integración de estos flujos de trabajo optimizados reduce de manera directa los costos de hospitalización y cuidado a largo plazo, consolidando el rol de los modelos de aprendizaje supervisado en la medicina preventiva personalizada.

IV. Entrenamiento y Evaluación de los Modelos

A. Configuración Experimental

Para garantizar una evaluación estadística robusta y libre de sesgos de selección, se adopta la metodología de validación cruzada estratificada de K pliegues (K-Fold Cross-Validation). Esta aproximación asegura que la proporción original de las clases de la variable objetivo se mantenga idéntica en cada partición de entrenamiento y prueba.

Atendiendo a los requerimientos del proyecto, se seleccionan y comparan de forma sistemática cinco modelos de aprendizaje pertenecientes a familias teóricas independientes:

1) **Modelo Paramétrico:** Regresión Logística, configurando el ajuste de fronteras lineales.
2) **Modelo No Paramétrico:** KNN, como clasificador basado en vecindades.
3) **Ensamble de Árboles:** *Random Forest* para evaluar la reducción de varianza por ensacado.
4) **Red Neuronal Artificial:** Perceptrón Multicapa (MLP) para capturar transformaciones abstractas.
5) **Máquina de Vectores de Soporte:** SVM con optimización de márgenes e introducción de funciones kernel.

El proceso de ajuste e identificación de configuraciones óptimas se realiza implementando una búsqueda en malla

(*Grid Search*) combinada con la validación cruzada. En la Tabla I se detalla la configuración del espacio de búsqueda diseñado para cada algoritmo bajo evaluación.

TABLA I
ESPACIO DE BÚSQUEDA DE HIPERPARÁMETROS PARA LOS MODELOS

Modelo	Hiperparámetro	Malla de Valores Evaluados
Regresión Logística	Tipo de penalización Parámetro de regularización (C)	['l1', 'l2', 'elasticnet'] [0.01, 0.1, 1.0, 10.0]
KNN	Número de vecinos Esquema de ponderación Métrica de distancia	[15, 31, 51] ['uniform', 'distance'] ['euclidean', 'manhattan']
Random Forest	Número de árboles Máxima profundidad	[50, 100, 200] [5, 10, 20]
Red Neuronal (MLP)	Arquitectura de capas ocultas Tasa de aprendizaje inicial	[(50,), (100,), (50, 50)] [0.001, 0.01, 0.1]
SVM	Función Kernel Parámetro de penalización (C)	['linear', 'rbf'] [0.1, 1.0, 10.0]

Para evaluar rigurosamente el rendimiento de los clasificadores binarios se seleccionan cuatro métricas estandarizadas derivadas de la matriz de confusión, proporcionando intervalos de confianza estadísticos para cada medición:

- **Exactitud (Accuracy):** Proporción global de predicciones correctas realizadas por el sistema.

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN} \tag{1}$$

- **Sensibilidad (Sensitivity / Recall):** Capacidad intrínseca del clasificador para identificar correctamente a los pacientes enfermos reales, métrica crítica en contextos médicos.

$$Sensitivity = \frac{VP}{VP + FN} \tag{2}$$

- **Especificidad (Specificity):** Capacidad para clasificar correctamente a los sujetos sanos o libres de riesgo cardiovascular.

$$Specificity = \frac{VN}{VN + FP} \tag{3}$$

- **Área Bajo la Curva ROC (AUC):** Métrica global que evalúa el rendimiento del modelo en todos los umbrales posibles de clasificación [7].

$$AUC = \int_0^1 TVP(TFP^{-1}(x))\, dx \tag{4}$$

B. Resultados del Análisis Exploratorio y Entrenamiento

Tras someter los datos crudos al filtro de plausibilidad clínica descrito en la Sección II, se eliminaron de forma efectiva 1,388 registros inconsistentes, consolidando un dataset limpio con 68,612 muestras estables. Los estadísticos descriptivos resultantes de este proceso de curaduría evidencian una normalización inmediata en los valores extremos de presión y antropometría.

La caracterización demográfica de la muestra depurada revela una población predominantemente madura, con una mediana de edad situada en los 54 años, lo cual resulta altamente consistente con los perfiles epidemiológicos de riesgo cardiovascular. Adicionalmente, se constata que la variable objetivo presenta una distribución cercana al 49% de prevalencia positiva, indicando un conjunto de datos perfectamente balanceado de forma natural que exime el uso de técnicas artificiales de sub o sobre-muestreo.

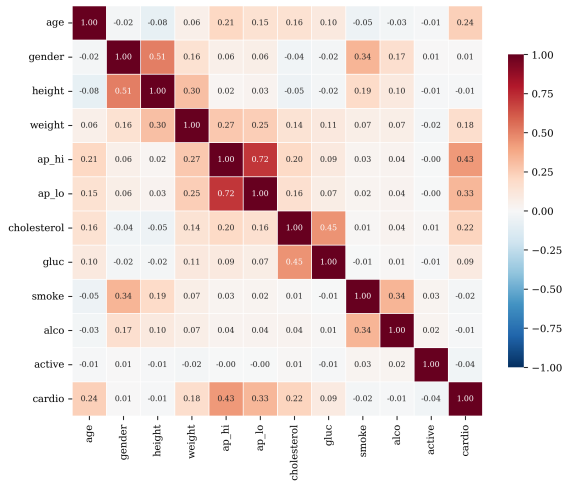


Fig. 1. Matriz de correlación lineal entre variables clínicas posterior al filtrado.

Por otra parte, la inspección de las interrelaciones lineales calculadas en la Figura 1 expone dinámicas de interés diagnóstico. La variable objetivo *cardio* exhibe coeficientes de correlación moderados con la presión sistólica (≈ 0.43) y diastólica (≈ 0.33), respaldando la correlación clínica establecida universalmente por la Organización Mundial de la Salud [1]. Factores conductuales como el tabaquismo y el consumo de alcohol revelan correlaciones lineales prácticamente nulas con la variable objetivo, sugiriendo que su impacto predictivo responde a patrones de interacción multivariados no lineales que justifican plenamente la introducción de arquitecturas complejas de Machine Learning.

La validación cruzada estratificada y la búsqueda en malla permitieron comparar de forma homogénea los cinco modelos definidos en la configuración experimental. En la Tabla II se resumen los resultados obtenidos en la partición de validación, donde se observa que el ensamble basado en árboles y la red neuronal artificial alcanzan el mejor desempeño global.

TABLA II
DESEMPEÑO DE LOS MODELOS EN VALIDACIÓN

Modelo	Accuracy	Precision	Recall	F1	ROC AUC
Random Forest	0.7347	0.7611	0.6762	0.7161	0.8007
MLP	0.7347	0.7468	0.7019	0.7236	0.7998
KNN	0.7265	0.7502	0.6705	0.7081	0.7947
Regresión Logística	0.7247	0.7509	0.6638	0.7047	0.7907
SVM	0.4952	0.4950	0.9990	0.6620	0.6586

La Tabla II muestra que *Random Forest* obtuvo el mejor desempeño global, seguido de forma muy cercana por el perceptrón multicapa (MLP). KNN y Regresión Logística presentaron valores competitivos y relativamente estables, mientras que SVM mostró el desempeño más bajo, lo que

sugiere una sensibilidad marcada a la configuración del kernel y a la escala de las variables.

Para complementar esta comparación, en la Tabla III se incluyen los intervalos de confianza al 95% del ROC-AUC estimado por validación cruzada para los dos mejores modelos.

TABLA III
INTERVALOS DE CONFIANZA AL 95% PARA ROC-AUC DE LOS MEJORES MODELOS

Modelo	ROC AUC medio CV	IC95	media $\pm$ IC95
Random Forest	0.7995	0.0059	0.7995 ± 0.0059
MLP	0.7978	0.0051	0.7978 ± 0.0051

Estos resultados confirman que ambos modelos no sólo presentan el mejor desempeño promedio, sino también una variabilidad reducida entre pliegues, lo que respalda su estabilidad para la tarea de clasificación planteada.

V. REDUCCIÓN DE DIMENSIÓN

A. Análisis Individual de Variables

Utilizando los coeficientes obtenidos en la matriz de correlación (Figura 1) y calculando los índices de discriminación individual, se identifican variables con baja capacidad explicativa lineal respecto a la variable objetivo *cardio*. Los hábitos comportamentales auto-reportados (*smoke*, *alco*, *active*) representan los candidatos principales a ser eliminados en estrategias de filtrado básico, dado que sus coeficientes directos no superan el valor absoluto de 0.10.

B. Extracción de Características Lineal (PCA)

Con el objetivo de comprimir el espacio de características proyectando los datos hacia ejes ortogonales de máxima varianza, se implementa el Análisis de Componentes Principales (PCA). Se utiliza el criterio de varianza explicada acumulada para seleccionar un número reducido de componentes que capturen al menos el 95% de la información estructural latente. Bajo este criterio se seleccionan 10 componentes, lo cual representa una reducción del 9.09% respecto al espacio original de 11 variables.

TABLA IV
COMPARACIÓN DEL DESEMPEÑO ORIGINAL FRENTE A PCA PARA LOS DOS MEJORES MODELOS

Representación	Modelo	Accuracy	Precision	Recall	F1	ROC AUC
Original	Random Forest	0.7347	0.7611	0.6762	0.7161	0.8007
Original	MLP	0.7347	0.7468	0.7019	0.7236	0.7998
PCA	MLP	0.7300	0.7485	0.6840	0.7148	0.7941
PCA	Random Forest	0.7305	0.7509	0.6813	0.7144	0.7918

Los resultados muestran que PCA conserva una fracción importante de la capacidad predictiva original, aunque con una leve disminución en ROC-AUC para ambos modelos. En este caso, la reducción dimensional permite simplificar el espacio de entrada sin comprometer de manera severa el desempeño.

C. Extracción de Características No Lineal (UMAP)

Reconociendo las limitaciones de los métodos proyectivos lineales frente a dinámicas biológicas complejas, se incorpora el uso de la técnica no lineal *Uniform Manifold Approximation and Projection* (UMAP). Este enfoque preserva las relaciones topológicas locales y globales del dataset en dimensiones reducidas. Se evaluaron configuraciones con 2, 3 y 5 componentes, y se seleccionó finalmente la proyección de 5 componentes como un compromiso razonable entre compresión y retención de información, alcanzando una reducción del 54.55% respecto al espacio original.

TABLA V
COMPARACIÓN DEL DESEMPEÑO ORIGINAL FRENTE A UMAP PARA LOS DOS MEJORES MODELOS

Representación	Modelo	Accuracy	Precision	Recall	F1	ROC AUC
Original	Random Forest	0.7347	0.7611	0.6762	0.7161	0.8007
Original	MLP	0.7347	0.7468	0.7019	0.7236	0.7998
UMAP	MLP	0.7251	0.7427	0.6801	0.7100	0.7423
UMAP	Random Forest	0.7247	0.7438	0.6767	0.7087	0.7346

A diferencia de PCA, UMAP logra una reducción más agresiva de la dimensionalidad, pero introduce una caída más evidente en la capacidad de predicción. Aun así, el método resulta útil para estudiar el equilibrio entre compresión y pérdida de información en escenarios donde la complejidad del modelo sea un factor relevante.

VI. EVALUACIÓN Y CONCLUSIONES

La evaluación completa muestra que la solución desarrollada cumple de forma satisfactoria con el objetivo de comparar varias familias de modelos, identificar un clasificador de mejor desempeño y analizar el efecto de la reducción de dimensión. En particular, *Random Forest* y MLP se consolidan como las alternativas más fuertes, con un ROC-AUC cercano a 0.80 y con una variación pequeña entre pliegues, lo que sugiere estabilidad en la partición de validación.

La comparación con PCA indica que es posible reducir el espacio de características sin una pérdida excesiva de desempeño, especialmente si se prioriza la simplificación del modelo y la interpretabilidad. En contraste, UMAP logra una reducción más notable, pero con una disminución mayor en la capacidad predictiva. Por tanto, PCA aparece como la alternativa más conservadora, mientras que UMAP resulta más útil como experimento de compresión no lineal.

Frente al estado del arte, los resultados son coherentes con lo reportado por Mo et al. [3] y Bibi et al. [4], quienes también destacan el buen comportamiento de los métodos de ensamble y de los enfoques de optimización sistemática de hiperparámetros. Asimismo, aunque SVM ha mostrado resultados competitivos en otros contextos [5], en este caso no alcanzó un desempeño comparable, lo que refuerza la importancia de ajustar el modelo al tipo de datos y a la configuración experimental seleccionada.

REFERENCIAS

[1] World Health Organization, "Cardiovascular diseases (CVDs)," Jul. 31, 2025. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)/

[2] G. A. Roth et al., "Global burden of cardiovascular diseases and risk factors, 1990–2019," *Journal of the American College of Cardiology*, vol. 76, no. 25, pp. 2982–3021, 2020.

[3] L. Mo, H. Lin, C. Li, L. Yu, and D. Lu, "Development and validation of a machine learning model for on-site prediction of coronary heart disease in high-risk adults using clinical data," *PLOS ONE*, vol. 20, no. 11, p. e0334881, 2025.

[4] I. Bibi et al., "Cardiovascular risk assessment enhanced by automated machine learning in a multi-phase study," *Scientific Reports*, vol. 15, p. 36474, 2025.

[5] I. A. Kakadiaris, M. Vrigkas, A. A. Yen, T. Kuznetsova, M. Budoff, and M. Naghavi, "Machine Learning Outperforms ACC/AHA CVD Risk Calculator in MESA," *Journal of the American Heart Association*, vol. 7, no. 22, p. e009476, Nov. 2018.

[6] D. Adusumilli, S. L. Damineni, S. Kailasam, N. Tenali, and R. Yadavalli, "Assessment of Cardiovascular Disease Using Machine Learning," *Revue d'Intelligence Artificielle*, vol. 38, no. 3, pp. 1035–1043, Jun. 2024.

[7] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.