Predicción del Riesgo de Enfermedad Cardiovascular usando Machine Learning y Datos Clínicos

Camilo A. Cuellar
Facultad de Ingeniería
Universidad de Antioquia
Medellín, Colombia
camilo.cuellar@udea.edu.co

Lukas Piedrahita
Facultad de Ingeniería
Universidad de Antioquia
Medellín, Colombia
lukas.piedrahita@udea.edu.co

Felipe Uribe
Facultad de Ingeniería
Universidad de Antioquia
Medellín, Colombia
f.uribe@udea.edu.co

***Resumen*—**
***Palabras Clave*—**

I. Introducción

Las enfermedades cardiovasculares constituyen una de las principales causas de morbilidad y mortalidad a nivel mundial, representando aproximadamente el 32% de todas las muertes globales [1], lo que hace necesario el desarrollo de herramientas que permitan su detección temprana y una adecuada estratificación del riesgo. El presente proyecto aborda este problema a partir de un conjunto de datos con 70,000 registros que integra variables objetivas, resultados de examen y factores subjetivos del paciente.

El uso de técnicas de Machine Learning (ML) resulta pertinente en este escenario debido a su capacidad para modelar relaciones complejas entre múltiples variables clínicas y comportamentales, facilitando la identificación de patrones asociados a la presencia de la enfermedad. En particular, el problema se formula como una tarea de clasificación binaria supervisada, donde el objetivo es predecir la variable de presencia o ausencia de enfermedad cardiovascular a partir de características como edad, presión arterial, colesterol, glucosa y hábitos de vida. Este enfoque permite plantear un sistema de apoyo al tamizaje clínico que, basado en datos históricos, contribuya a la detección oportuna de pacientes en riesgo.

II. Descripción del Problema

Se estima que aproximadamente 523 millones de personas en el mundo viven con alguna forma de enfermedad cardiovascular, lo que refleja su alta prevalencia a nivel global [2]. Este impacto las posiciona como un problema crítico de salud pública que requiere herramientas efectivas para su detección temprana y gestión del riesgo. En este contexto, el uso de ML permite aprovechar datos clínicos para poder identificar patrones asociados a la enfermedad, facilitando el desarrollo de sistemas de apoyo a la toma de decisiones médicas.

El conjunto de datos utilizado contiene 70,000 muestras, sin valores faltantes, y está compuesto por 11 variables de entrada y 1 variable objetivo (cardio), la cual indica la presencia o ausencia de enfermedad cardiovascular. Las variables incluyen información objetiva (edad, estatura, peso, género), resultados de examen (presión sistólica ap_hi, presión diastólica ap_lo, colesterol, glucosa) y factores subjetivos (consumo de tabaco, alcohol y actividad física). La descripción detallada de las variables, incluyendo su tipo y codificación, se presenta en la Tabla 1:

TABLA I
Variables del dataset y su codificación

Variable	Tipo	Codificación/Unidad	Descripción
age	Numérica	Días	Edad del paciente
height	Numérica	cm	Estatura
weight	Numérica	kg	Peso corporal
gender	Categórica	1, 2[a]	Género del paciente
ap_hi	Numérica	mmHg	Presión sistólica
ap_lo	Numérica	mmHg	Presión diastólica
cholesterol	Ordinal	1, 2, 3[b]	Nivel de colesterol
gluc	Ordinal	1, 2, 3[b]	Nivel de glucosa
smoke	Binaria	0, 1[c]	Hábito de fumar
alco	Binaria	0, 1[c]	Consumo de alcohol
active	Binaria	0, 1[c]	Actividad física
cardio	Binaria	0, 1[c]	Enfermedad cardiovascular

[a] 1: mujer, 2: hombre.
[b] 1: normal, 2: elevado, 3: muy elevado.
[c] 0: no, 1: sí.

Durante el análisis exploratorio se identificaron valores inconsistentes en variables clave como estatura, peso y presión arterial. En particular, se observaron registros con valores fisiológicamente implausibles, tales como presiones arteriales negativas o excesivamente altas (por ejemplo, valores superiores a 10,000 mmHg), lo que sugiere errores de digitación.

Con el fin de garantizar la calidad de los datos, se realizó un proceso de limpieza basado en rangos de plausibilidad clínica. Para las variables de presión arterial, se adoptaron límites reportados en la literatura ("Table 2: Definitions of plausible data used in data extraction programming" de [7]), estableciendo intervalos de 50–260 mmHg para presión sistólica y 0–200 mmHg para presión diastólica. Adicionalmente, se definieron rangos para variables antropométricas: 100–250 cm

para estatura y 40–200 kg para peso, con el objetivo de eliminar valores erróneos sin afectar la variabilidad clínica relevante.

Como resultado de este proceso, se eliminaron 1,407 registros. Los estadísticos descriptivos del conjunto de datos posterior a la limpieza se presentan en la Tabla 2, donde se evidencia una mejora significativa en la consistencia de las variables. Adicionalmente, se calculó la matriz de correlación entre variables, la cual se muestra en la Figura 3, con el objetivo de analizar las relaciones lineales presentes en los datos.

TABLA II
ESTADÍSTICOS DESCRIPTIVOS DEL DATASET DESPUÉS DEL PROCESO DE LIMPIEZA

Variable	Mean	Std	Min	Q1	Median	Q3	Max
age_years	53.32	6.76	29.58	48.37	53.97	58.42	64.97
gender	1.35	0.48	1	1	1	2	2
height	164.40	7.97	100	159	165	170	250
weight	74.13	14.27	40	65	72	82	200
ap_hi	126.61	16.51	60	120	120	140	200
ap_lo	81.24	9.56	0	80	80	90	182
cholesterol	1.36	0.68	1	1	1	1	3
gluc	1.23	0.57	1	1	1	1	3
smoke	0.09	0.28	0	0	0	0	1
alco	0.05	0.22	0	0	0	0	1
active	0.80	0.40	0	1	1	1	1
cardio	0.49	0.50	0	0	0	1	1

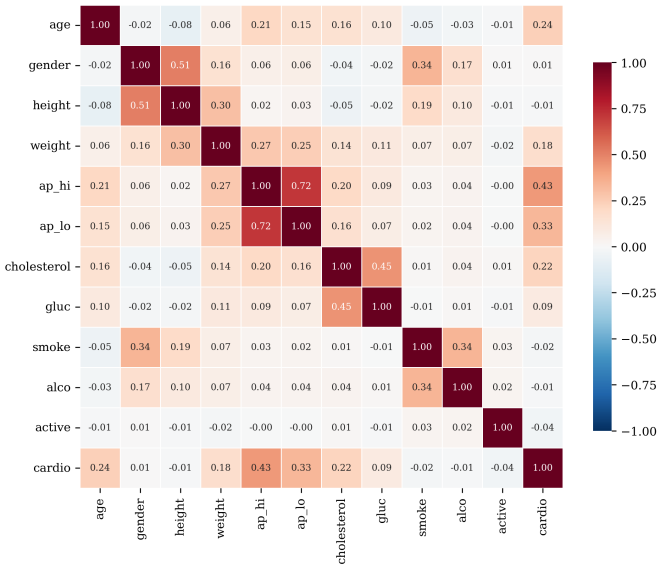


Fig. 1. Matriz de correlación entre variables del dataset después del proceso de limpieza.

A partir de los resultados presentados en la Tabla 2, se observa que la población está compuesta mayoritariamente por adultos de mediana edad (de 48 a 58 años) lo cual es consistente con una población en riesgo cardiovascular. En términos demográficos, hay una mayor proporción de mujeres en el dataset, lo que podría influir en la distribución de algunas variables clínicas.

Por otra parte, el análisis de la matriz de correlación permite identificar relaciones relevantes entre variables. En particular, la variable objetivo cardio presenta una correlación moderada con la presión sistólica (≈ 0.43) y diastólica (≈ 0.33), lo cual es consistente con la evidencia clínica [1]. También se observan correlaciones positivas, aunque menores, con variables como la edad y el colesterol. En contraste, factores como el tabaquismo, consumo de alcohol y actividad física muestran baja correlación lineal con la variable objetivo.

Finalmente, se observa que no hay valores faltantes y que la variable objetivo presenta una prevalencia cercana al 50%, lo que indica que el conjunto de datos se encuentra balanceado en términos de clases, favoreciendo el entrenamiento y evaluación de modelos de clasificación sin necesidad de aplicar técnicas adicionales de balanceo ni imputación.

Dado que la variable objetivo es binaria y se dispone de ejemplos etiquetados, el problema se formula como uno de *aprendizaje supervisado para clasificación binaria*. Este enfoque es adecuado porque permite entrenar modelos que aprendan una función de decisión a partir de las variables de entrada, con el objetivo de predecir la clase cardio. La naturaleza de los datos, que combina variables continuas, categóricas y binarias, refuerza la pertinencia de evaluar diferentes modelos de clasificación capaces de capturar relaciones no lineales y dependencias entre variables.

III. ESTADO DEL ARTE

El desarrollo de modelos de aprendizaje automático (Machine Learning, ML) para la predicción del riesgo de enfermedades cardiovasculares (CVD) ha evolucionado significativamente, integrando desde algoritmos clásicos hasta arquitecturas híbridas y sistemas automatizados. A continuación, se describen los trabajos más relevantes en este campo considerando la configuración, técnicas, validación y métricas empleadas.

A. Análisis de Trabajos Relacionados

En [4], se propone un paradigma de aprendizaje supervisado mediante un modelo de dos capas denominado TLML (*Two-Layer Machine Learning*). Esta técnica combina los algoritmos *Random Forest* (RF) y *Gradient Boosting Decision Tree* (GBDT). La validación se realizó de forma retrospectiva con una cohorte hospitalaria de 30,617 pacientes. Los resultados mostraron una precisión, sensibilidad y especificidad de 0.79, superando el desempeño de las ecuaciones tradicionales de cohorte agrupada (PCEs).

Por su parte, [5] utiliza un paradigma de aprendizaje supervisado basado en ML automatizado (AutoML). Se emplearon diversas técnicas como *eXtreme Gradient Boosted Trees* (EGBTC), clasificadores *Elastic-Net* (ENET) y redes neuronales residuales profundas. La metodología de validación incluyó tres fases con los conjuntos de datos LURIC y UMC/M, incorporando validación externa y análisis de SHAP para interpretabilidad. Los resultados arrojaron valores de AUC entre 0.62 y 0.91 en la fase inicial, y entre 0.74 y 0.85 para la predicción de mortalidad.

En el trabajo de [6], se emplea un paradigma supervisado utilizando *Support Vector Machines* (SVM) junto con la técnica NEATER para el manejo de datos desbalanceados. La validación consistió en una validación cruzada de 2 pliegues repetida 10 veces, utilizando el estudio MESA ($n = 6459$) y validación externa con el estudio FLEMENGHO. El sistema alcanzó una sensibilidad de 0.86 y una especificidad de 0.95, con un AUC de 0.92, superando significativamente las calculadoras de riesgo ACC/AHA convencionales.

Finalmente, [7] presenta un estudio supervisado comparando técnicas de Regresión Logística, *Random Forest* y SVM aplicadas a registros de salud electrónicos (EHRs). La metodología de validación se centró en la robustez del entrenamiento sobre grandes volúmenes de datos clínicos. Los resultados indicaron que los modelos de ML mejoran la precisión y eficiencia en la detección temprana en comparación con métodos diagnósticos previos.

B. Métricas de Evaluación y Definiciones Matemáticas

Para evaluar el desempeño de los sistemas de clasificación propuestos, se utilizan métricas basadas en la matriz de confusión, donde VP son verdaderos positivos, VN verdaderos negativos, FP falsos positivos y FN falsos negativos.

1) **Exactitud (Accuracy):** Es la proporción de predicciones correctas sobre el total de casos.

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN} \tag{1}$$

2) **Sensibilidad (Sensitivity / Recall):** Mide la capacidad del sistema para detectar los casos positivos reales.

$$Sensitivity = \frac{VP}{VP + FN} \tag{2}$$

3) **Especificidad (Specificity):** Mide la capacidad del sistema para identificar correctamente los casos negativos.

$$Specificity = \frac{VN}{VN + FP} \tag{3}$$

4) **Área Bajo la Curva ROC (AUC):** Representa la probabilidad de que el modelo clasifique un ejemplo positivo aleatorio más alto que uno negativo. Se define como la integral de la curva ROC:

$$AUC = \int_0^1 TVP(TFP^{-1}(x))\,dx \tag{4}$$

Donde TVP es la tasa de verdaderos positivos y TFP es la tasa de falsos positivos.

REFERENCIAS

[1] World Health Organization, "Cardiovascular diseases (CVDs)," Jul. 31, 2025. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)/

[2] G. A. Roth et al., "Global burden of cardiovascular diseases and risk factors, 1990–2019," *Journal of the American College of Cardiology*, vol. 76, no. 25, pp. 2982–3021, 2020.

[3] E. Cottrell, T. Cox, P. O'Connell, et al., "Implementation of simple telehealth to manage hypertension in general practice: a service evaluation," *BMC Family Practice*, vol. 16, art. no. 83, 2015, doi: 10.1186/s12875-015-0301-2.

[4] L. Mo, H. Lin, C. Li, L. Yu, and D. Lu, "Development and validation of a machine learning model for on-site prediction of coronary heart disease in high-risk adults using clinical data," *PLOS ONE*, vol. 20, no. 11, p. e0334881, 2025.

[5] I. Bibi et al., "Cardiovascular risk assessment enhanced by automated machine learning in a multi-phase study," *Scientific Reports*, vol. 15, p. 36474, 2025.

[6] I. A. Kakadiaris, M. Vrigkas, A. A. Yen, T. Kuznetsova, M. Budoff, and M. Naghavi, "Machine Learning Outperforms ACC/AHA CVD Risk Calculator in MESA," *Journal of the American Heart Association*, vol. 7, no. 22, p. e009476, Nov. 2018.

[7] D. Adusumilli, S. L. Damineni, S. Kailasam, N. Tenali, and R. Yadavalli, "Assessment of Cardiovascular Disease Using Machine Learning," *Revue d'Intelligence Artificielle*, vol. 38, no. 3, pp. 1035–1043, Jun. 2024.